Detección de fraudes con tarjetas de crédito

Enlace al dataset: https://www.kaggle.com/datasets/mlg-ulb/creditcardfraud

Notas previas de Mi Proyecto (Importante leer primero)

Para elaborar este proyecto, he seguido las instrucciones del Notebook y tambíen las sesiones informativas de Hugo y las 3 AMAs.

En la fase de importación de datos y verificación he querido usar (Describe y Info) para profundizar en la naturaleza del dataset y tener más información.

Se ha decidido y confirmado en AMA con Hugo que en este caso al ser proyecto pequeño, valía la pena usar variables distintas para almacenar las distintas fases del dataset. Finalizando con (data_limpia) para el dataset limpiado.

En la parte final del proyecto, antes de ntrenar el módelo, he estandarizado los datos con (scaler) tal y como pedía Hugo, además en varias pruebas que he hecho sin estandarizar para RandomForest y SVM, la conclusión es que la estandarización de los datos, no afecta para nada en los resultados obtenidos con el método Randomforest, mientras que usando el modelo de vectores SVM sin estandarizar he detectado que daba resultados erroneos, y que por lo tanto el modelo SVM sin estandarizar no era válido. Por este motivo no muestro pruebas sin estandarizar.

Finalmente he usado dos metodos distintos de entrenamiento del modelo para averiguar cual daba mejor resultado, siendo el método RandomForest el que obtenia mejores valoraciones y resultados a la hora de predecir las operaciones fraudulentas.

Conclusión: Por último al final de todo el proceso, aprovechando el curso que nos han dado de Chat-GPT, he usado los conocimientos adquiridos para que Chat-GPT analice los resultados obtenidos, os pongo sus conclusiones al final.

Importa las bibliotecas necesarias

```
In [68]: # Importa la bibliotecas necesarias
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns

import warnings
warnings.filterwarnings("ignore")
```

Importa y organiza el dataset

```
In [71]: # Organizar los datos en un dataframe

data = pd.read_csv("creditcard.csv")

data.head(10)
```

Out[71]:

	Time	V1	V2	V3	V4	V5	V6	V7	V8	V9	...	V21	V22	V23	V24	V25	V26	V27	V28	Amount	Clas
0	0.0	-1.359807	-0.072781	2.536347	1.378155	-0.338321	0.462388	0.239599	0.098698	0.363787	...	-0.018307	0.277838	-0.110474	0.066928	0.128539	-0.189115	0.133558	-0.021053	149.62	
1	0.0	1.191857	0.266151	0.166480	0.448154	0.060018	-0.082361	-0.078803	0.085102	-0.255425	...	-0.225775	-0.638672	0.101288	-0.339846	0.167170	0.125895	-0.008983	0.014724	2.69	
2	1.0	-1.358354	-1.340163	1.773209	0.379780	-0.503198	1.800499	0.791461	0.247676	-1.514654	...	0.247998	0.771679	0.909412	-0.689281	-0.327642	-0.139097	-0.055353	-0.059752	378.66	
3	1.0	-0.966272	-0.185226	1.792993	-0.863291	-0.010309	1.247203	0.237609	0.377436	-1.387024	...	-0.108300	0.005274	-0.190321	-1.175575	0.647376	-0.221929	0.062723	0.061458	123.50	
4	2.0	-1.158233	0.877737	1.548718	0.403034	-0.407193	0.095921	0.592941	-0.270533	0.817739	...	-0.009431	0.798278	-0.137458	0.141267	-0.206010	0.502292	0.219422	0.215153	69.99	
5	2.0	-0.425966	0.960523	1.141109	-0.168252	0.420987	-0.029728	0.476201	0.260314	-0.568671	...	-0.208254	-0.559825	-0.026398	-0.371427	-0.232794	0.105915	0.253844	0.081080	3.67	
6	4.0	1.229658	0.141004	0.045371	1.202613	0.191881	0.272708	-0.005159	0.081213	0.464960	...	-0.167716	-0.270710	-0.154104	-0.780055	0.750137	-0.257237	0.034507	0.005168	4.99	
7	7.0	-0.644269	1.417964	1.074380	-0.492199	0.948934	0.428118	1.120631	-3.807864	0.615375	...	1.943465	-1.015455	0.057504	-0.649709	-0.415267	-0.051634	-1.206921	-1.085339	40.80	
8	7.0	-0.894286	0.286157	-0.113192	-0.271526	2.669599	3.721818	0.370145	0.851084	-0.392048	...	-0.073425	-0.268092	-0.204233	1.011592	0.373205	-0.384157	0.011747	0.142404	93.20	
9	9.0	-0.338262	1.119593	1.044367	-0.222187	0.499361	-0.246761	0.651583	0.069539	-0.736727	...	-0.246914	-0.633753	-0.120794	-0.385050	-0.069733	0.094199	0.246219	0.083076	3.68	

10 rows × 31 columns

```
In [73]: data.describe()
```

Out[73]:

	Time	V1	V2	V3	V4	V5	V6	V7	V8	V9	...	V21	V22	V23	
count	284807.000000	2.848070e+05	2.848070e+05	2.848070e+05	2.848070e+05	2.848070e+05	2.848070e+05	2.848070e+05	2.848070e+05	2.848070e+05	...	2.848070e+05	2.848070e+05	2.848070e+05	2.8480
mean	94813.859575	1.168375e-15	3.416908e-16	-1.379537e-15	2.074095e-15	9.604066e-16	1.487313e-15	-5.556467e-16	1.213481e-16	-2.406331e-15	...	1.654067e-16	-3.568593e-16	2.578648e-16	4.473
std	47488.145955	1.958696e+00	1.651309e+00	1.516255e+00	1.415869e+00	1.380247e+00	1.332271e+00	1.237094e+00	1.194353e+00	1.098632e+00	...	7.345240e-01	7.257016e-01	6.244603e-01	6.056
min	0.000000	-5.640751e+01	-7.271573e+01	-4.832559e+01	-5.683171e+00	-1.137433e+02	-2.616051e+01	-4.355724e+01	-7.321672e+01	-1.343407e+01	...	-3.483038e+01	-1.093314e+01	-4.480774e+01	-2.8366
25%	54201.500000	-9.203734e-01	-5.985499e-01	-8.903648e-01	-8.486401e-01	-6.915971e-01	-7.682956e-01	-5.540759e-01	-2.086297e-01	-6.430976e-01	...	-2.283949e-01	-5.423504e-01	-1.618463e-01	-3.545
50%	84692.000000	1.810880e-02	6.548556e-02	1.798463e-01	-1.984653e-02	-5.433583e-02	-2.741871e-01	4.010308e-02	2.235804e-02	-5.142873e-02	...	-2.945017e-02	6.781943e-03	-1.119293e-02	4.0976
75%	139320.500000	1.315642e+00	8.037239e-01	1.027196e+00	7.433413e-01	6.119264e-01	3.985649e-01	5.704361e-01	3.273459e-01	5.971390e-01	...	1.863772e-01	5.285536e-01	1.476421e-01	4.3952
max	172792.000000	2.454930e+00	2.205773e+01	9.382558e+00	1.687534e+01	3.480167e+01	7.330163e+01	1.205895e+02	2.000721e+01	1.559499e+01	...	2.720284e+01	1.050309e+01	2.252841e+01	4.5845

8 rows × 31 columns

```
In [10]: data.info()

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 284807 entries, 0 to 284806
Data columns (total 31 columns):
 #   Column  Non-Null Count   Dtype  
---  ------  --------------   -----  
 0   Time    284807 non-null  float64
 1   V1      284807 non-null  float64
 2   V2      284807 non-null  float64
 3   V3      284807 non-null  float64
 4   V4      284807 non-null  float64
 5   V5      284807 non-null  float64
 6   V6      284807 non-null  float64
 7   V7      284807 non-null  float64
 8   V8      284807 non-null  float64
 9   V9      284807 non-null  float64
 10  V10     284807 non-null  float64
 11  V11     284807 non-null  float64
 12  V12     284807 non-null  float64
 13  V13     284807 non-null  float64
 14  V14     284807 non-null  float64
 15  V15     284807 non-null  float64
 16  V16     284807 non-null  float64
 17  V17     284807 non-null  float64
 18  V18     284807 non-null  float64
 19  V19     284807 non-null  float64
 20  V20     284807 non-null  float64
 21  V21     284807 non-null  float64
 22  V22     284807 non-null  float64
 23  V23     284807 non-null  float64
 24  V24     284807 non-null  float64
 25  V25     284807 non-null  float64
 26  V26     284807 non-null  float64
 27  V27     284807 non-null  float64
 28  V28     284807 non-null  float64
 29  Amount  284807 non-null  float64
 30  Class   284807 non-null  int64  
dtypes: float64(30), int64(1)
memory usage: 67.4 MB
```

▶ **Haz clic aquí para obtener una pista**

Limpia los datos

a. Valores perdidos

```
In [14]: #Escribe tu código aquí
valores_nulos = data.isnull().sum()
print (valores_nulos)
data_sin_nulos = data.dropna()
data_sin_nulos

Time      0
V1        0
V2        0
V3        0
V4        0
V5        0
V6        0
V7        0
V8        0
V9        0
V10       0
V11       0
V12       0
V13       0
V14       0
V15       0
V16       0
V17       0
V18       0
V19       0
V20       0
V21       0
V22       0
V23       0
V24       0
V25       0
V26       0
V27       0
V28       0
Amount    0
Class     0
dtype: int64
```

Out[14]:

	Time	V1	V2	V3	V4	V5	V6	V7	V8	V9	...	V21	V22	V23	V24	V25	V26	V27	V28	Ar
0	0.0	-1.359807	-0.072781	2.536347	1.378155	-0.338321	0.462388	0.239599	0.098698	0.363787	...	-0.018307	0.277838	-0.110474	0.066928	0.128539	-0.189115	0.133558	-0.021053	
1	0.0	1.191857	0.266151	0.166480	0.448154	0.060018	-0.082361	-0.078803	0.085102	-0.255425	...	-0.225775	-0.638672	0.101288	-0.339846	0.167170	0.125895	-0.008983	0.014724	
2	1.0	-1.358354	-1.340163	1.773209	0.379780	-0.503198	1.800499	0.791461	0.247676	-1.514654	...	0.247998	0.771679	0.909412	-0.689281	-0.327642	-0.139097	-0.055353	-0.059752	
3	1.0	-0.966272	-0.185226	1.792993	-0.863291	-0.010309	1.247203	0.237609	0.377436	-1.387024	...	-0.108300	0.005274	-0.190321	-1.175575	0.647376	-0.221929	0.062723	0.061458	
4	2.0	-1.158233	0.877737	1.548718	0.403034	-0.407193	0.095921	0.592941	-0.270533	0.817739	...	-0.009431	0.798278	-0.137458	0.141267	-0.206010	0.502292	0.219422	0.215153	
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	
284802	172786.0	-11.881118	10.071785	-9.834783	-2.066656	-5.364473	-2.606837	-4.918215	7.305334	1.914428	...	0.213454	0.111864	1.014480	-0.509348	1.436807	0.250034	0.943651	0.823731	
284803	172787.0	-0.732789	-0.055080	2.035030	-0.738589	0.868229	1.058415	0.024330	0.294869	0.584800	...	0.214205	0.924384	0.012463	-1.016226	-0.606624	-0.395255	0.068472	-0.053527	
284804	172788.0	1.919565	-0.301254	-3.249640	-0.557828	2.630515	3.031260	-0.296827	0.708417	0.432454	...	0.232045	0.578229	-0.037501	0.640134	0.265745	-0.087371	0.004455	-0.026561	
284805	172788.0	-0.240440	0.530483	0.702510	0.689799	-0.377961	0.623708	-0.686180	0.679145	0.392087	...	0.265245	0.800049	-0.163298	0.123205	-0.569159	0.546668	0.108821	0.104533	
284806	172792.0	-0.533413	-0.189733	0.703337	-0.506271	-0.012546	-0.649617	1.577006	-0.414650	0.486180	...	0.261057	0.643078	0.376777	0.008797	-0.473649	-0.818267	-0.002415	0.013649	

284807 rows × 31 columns

▶ **Haz clic aquí para obtener una pista**

b. Datos duplicados

```
In [17]: #Escribe tu código aquí
filas_duplicadas = data_sin_nulos.duplicated().sum()
print (filas_duplicadas)

1081
```

```
In [18]: # El dataset definitivo limpio con que trabajare lo almacenare en la variable "data_limpia"
data_limpia = data_sin_nulos.drop_duplicates()
data_limpia.describe()
```

Out[18]:

	Time	V1	V2	V3	V4	V5	V6	V7	V8	V9	...	V21	V22	V
count	283726.000000	283726.000000	283726.000000	283726.000000	283726.000000	283726.000000	283726.000000	283726.000000	283726.000000	283726.000000	...	283726.000000	283726.000000	283726.0000
mean	94811.077600	0.005917	-0.004135	0.001613	-0.002966	0.001828	-0.001139	0.001801	-0.000854	-0.001596	...	-0.000371	-0.000015	0.0001
std	47481.047891	1.948026	1.646703	1.508682	1.414184	1.377008	1.331931	1.227664	1.179054	1.095492	...	0.723909	0.724550	0.6237
min	0.000000	-56.407510	-72.715728	-48.325589	-5.683171	-113.743307	-26.160506	-43.557242	-73.216718	-13.434066	...	-34.830382	-10.933144	-44.8077
25%	54204.750000	-0.915951	-0.600321	-0.889682	-0.850134	-0.689830	-0.769031	-0.552509	-0.208828	-0.644221	...	-0.228305	-0.542700	-0.1617
50%	84692.500000	0.020384	0.063949	0.179963	-0.022248	-0.053468	-0.275168	0.040859	0.021898	-0.052596	...	-0.029441	0.006675	-0.0111
75%	139298.000000	1.316068	0.800283	1.026960	0.739647	0.612218	0.396792	0.570474	0.325704	0.595977	...	0.186194	0.528245	0.1477
max	172792.000000	2.454930	22.057729	9.382558	16.875344	34.801666	73.301626	120.589494	20.007208	15.594995	...	27.202839	10.503090	22.5284

8 rows × 31 columns

▶ **Haz clic aquí para obtener una pista**

Analiza los datos

Pregunta 1: ¿Cuál es el porcentaje de transacciones fraudulentas en el dataset?

```
In [22]: # Calcula el porcentaje de transacciones fraudulentas

# Número total de transacciones y transacciones fraudulentas
transacciones_fraud = data_limpia['Class'].sum()
transacciones_tot = len(data_limpia)

# Porcentaje de transacciones fraudulentas : lo calculo y almaceno en la variable "porcentaje_fraud"
porcentaje_fraud = (transacciones_fraud / transacciones_tot) * 100

# Muestra el porcentaje de transacciones fraudulentas almacenado en la variable uilizando el método formateo de cadenas en Python

print(f"El porcentaje de transacciones fraudulentas es: {porcentaje_fraud:.4f}%")

El porcentaje de transacciones fraudulentas es: 0.1667%
```

▶ **Haz clic aquí para obtener una pista**

Pregunta 2: ¿Cuál es el importe medio de las transacciones fraudulentas?

```
In [25]: # Calcula el importe medio de las transacciones fraudulentas

# Transacciones fraudulentas
transacciones_fraud = data_limpia[data_limpia['Class'] == 1]

# Cálculo media
media_transacciones_fraud = transacciones_fraud['Amount'].mean()

# Muestra el importe medio de las transacciones fraudulentas uilizando el método formateo de cadenas en Python

print(f"El importe medio de las transacciones fraudulentas es: {media_transacciones_fraud:.2f}")

El importe medio de las transacciones fraudulentas es: 123.87
```

▶ **Haz clic aquí para obtener una pista**

Visualiza los datos

Pregunta 1: ¿Cuántas transacciones fraudulentas hay en comparación con las no fraudulentas? (Utiliza un gráfico de barras)

```
In [29]: # Cuenta el número de transacciones fraudulentas y no fraudulentes
conteo_fraud = data_limpia['Class'].value_counts()
print (conteo_fraud)

# Muestra la distribución de las traducciones fraudulentas con respecto de las no fraudulentas
plt.figure(figsize=(8, 6))
sns.barplot(x=conteo_fraud.index, y=conteo_fraud.values, palette='deep')

# Pongo etiquetas y título al gráfico
plt.title('Distribución de Transacciones Fraudulentas vs No Fraudulentas')
plt.xlabel('Tipo de Transacciónes')
plt.ylabel('Cantidad de Transacciones')
plt.xticks([0, 1], ['0: No Fraudulentas', '1: Fraudulentas'])

# Gráfico
plt.show()

Class
0    283253
1       473
Name: count, dtype: int64
```

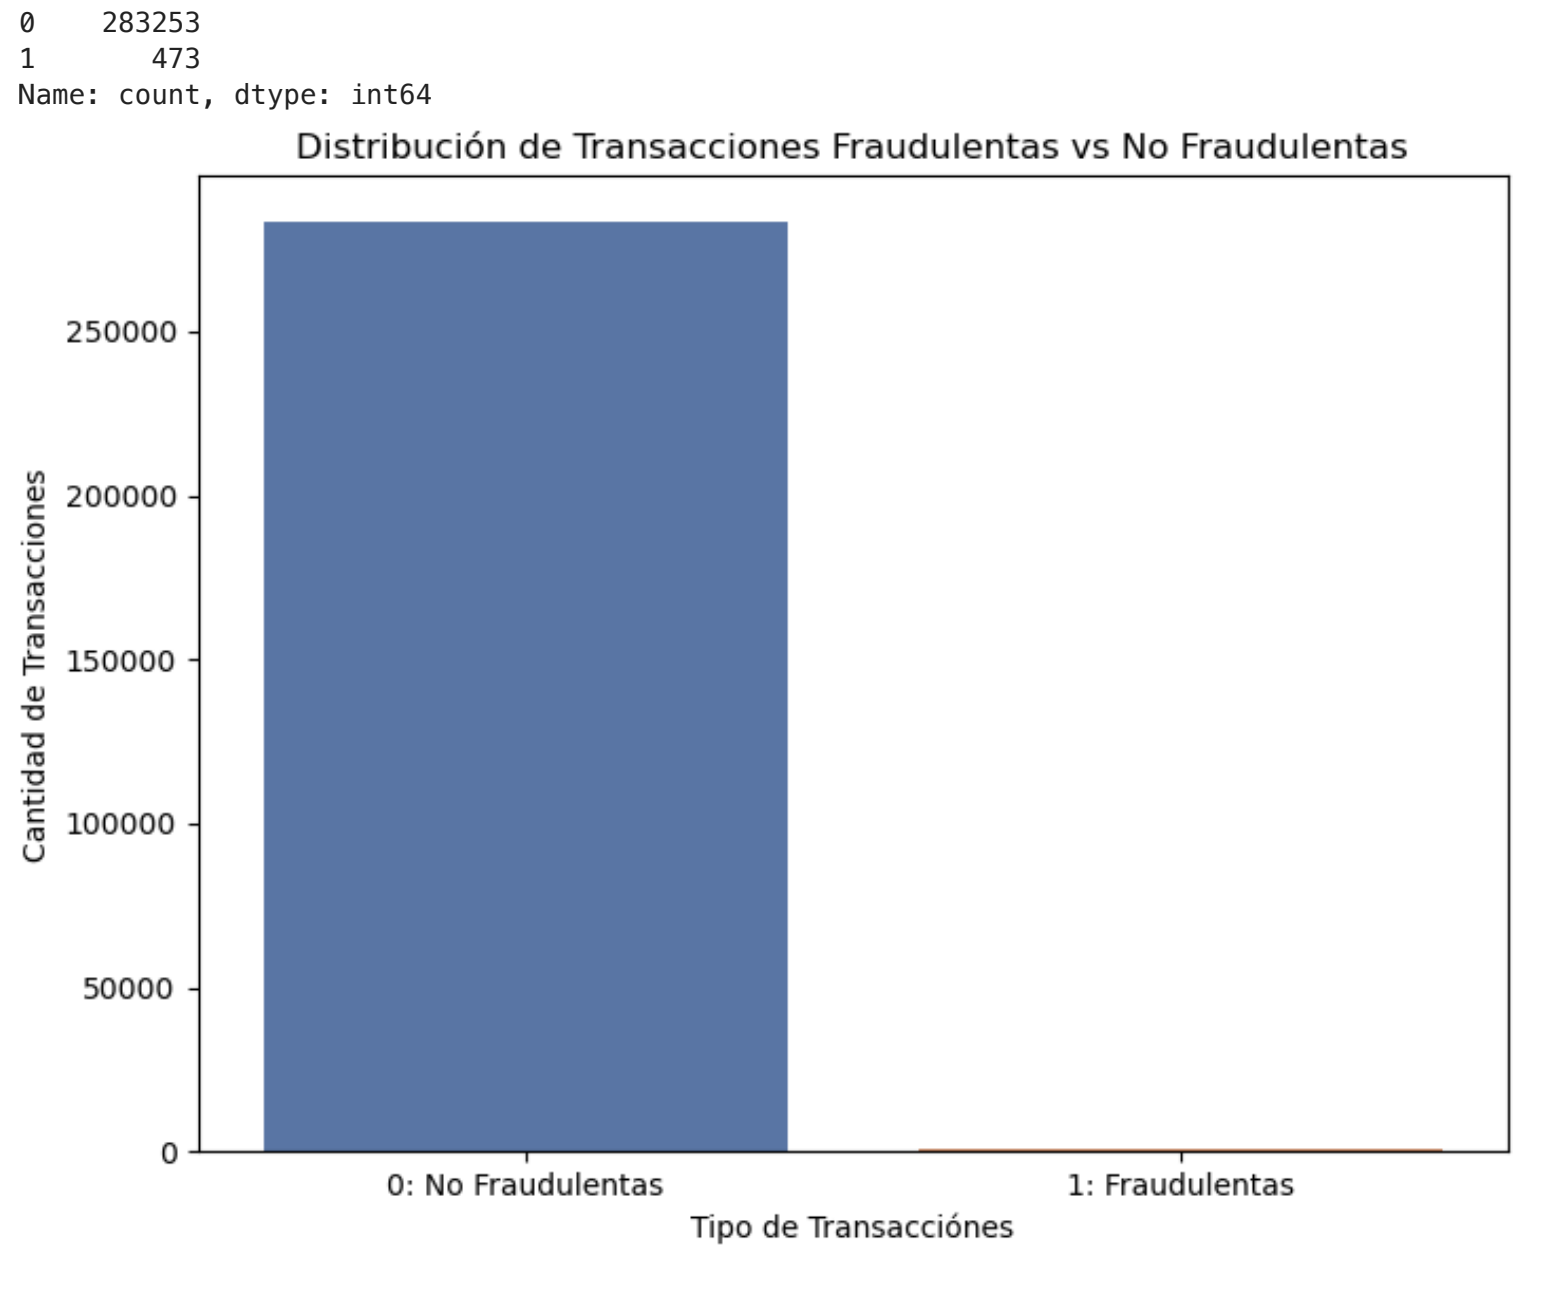

▶ **Haz clic aquí para obtener una pista**

Pregunta 2: ¿Cuál es la distribución de los importes de las transacciones fraudulentas? (Utiliza un histograma)

```
In [32]: # Separa los datos de transacciones fraudulentas
transacciones_fraud = data_limpia[data_limpia['Class'] == 1]

# Muestra la distribución de los importes de las transacciones fraudulentas
plt.figure(figsize=(8, 6))
sns.histplot(transacciones_fraud['Amount'], bins=50, palette="deep")

# # Pongo etiquetas y título al gráfico
plt.title('Distribución de los Importes de las Transacciones Fraudulentas')
plt.xlabel('Importe de la Transacción')
plt.ylabel('Cantidad de Transacciones')

# Mostrar el gráfico
plt.show()
```

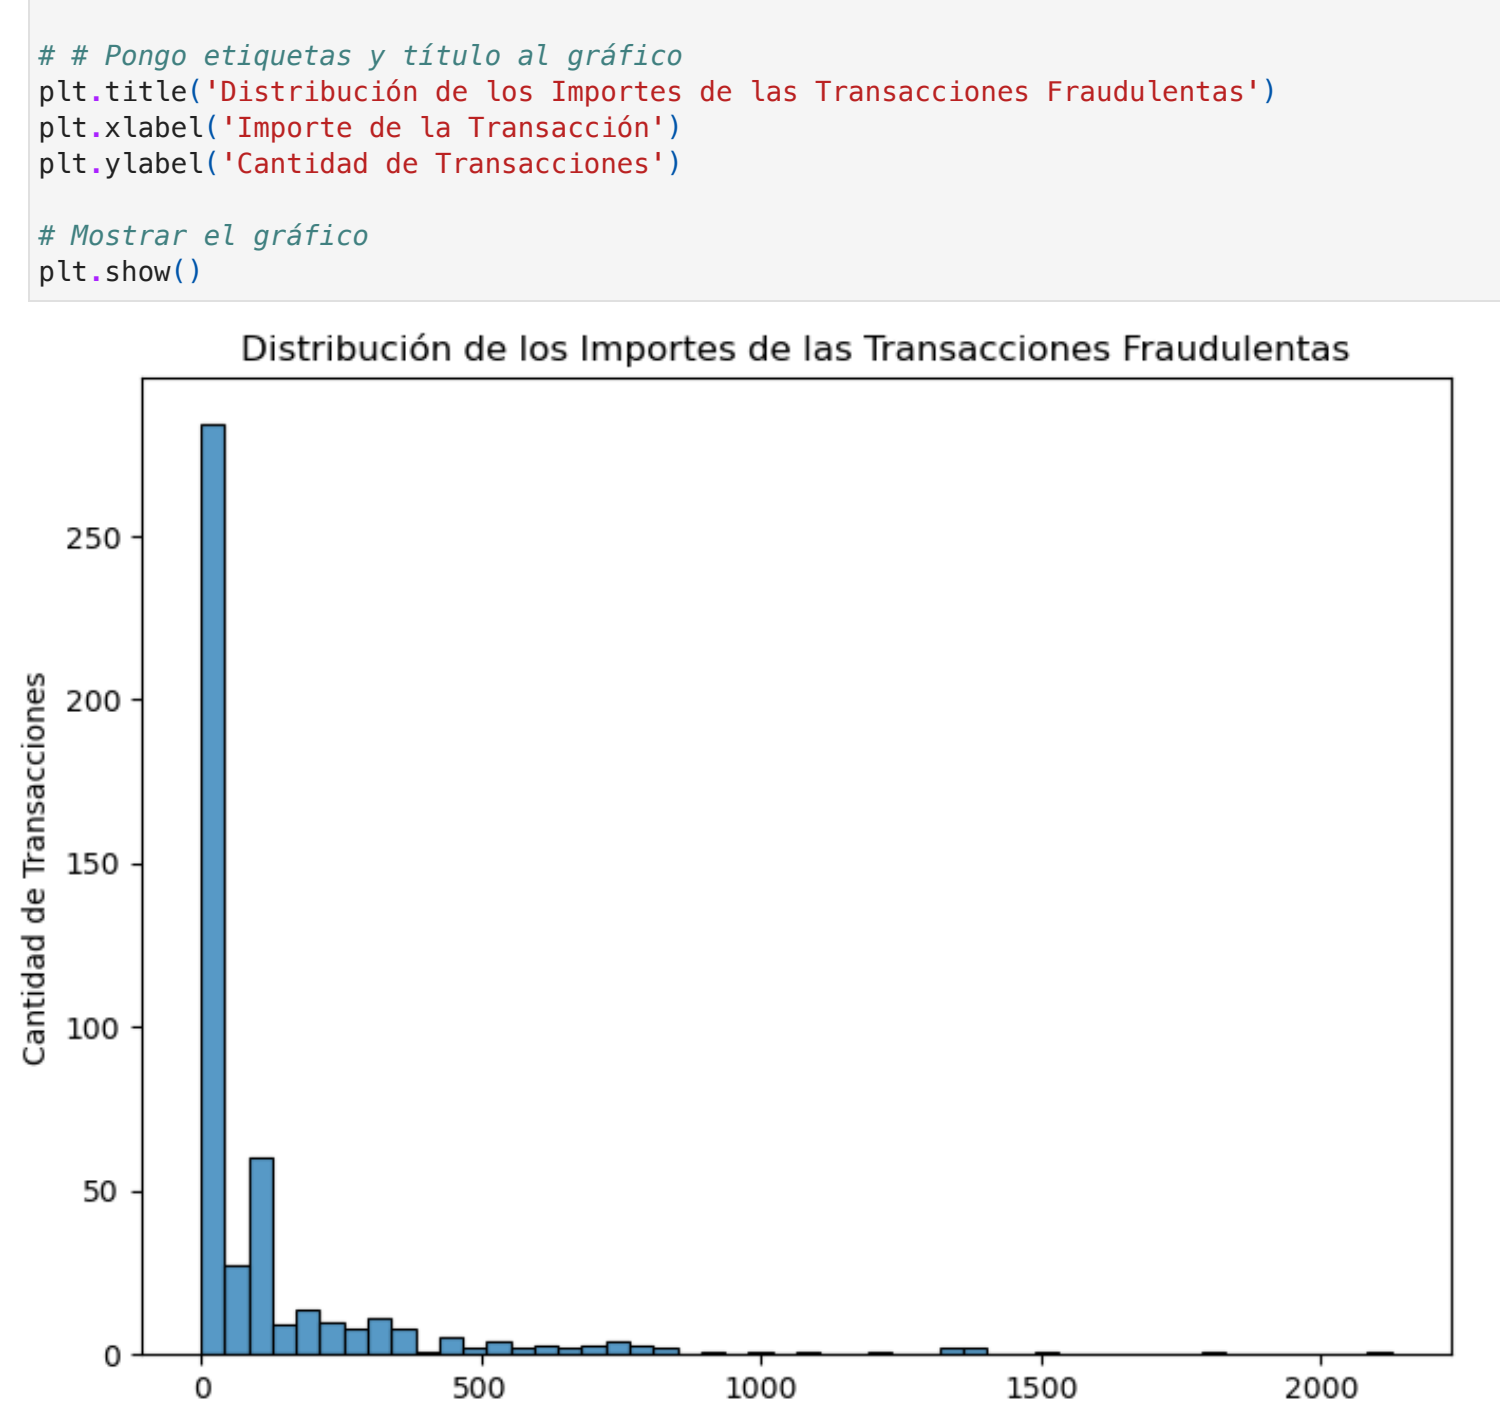

▶ **Haz clic aquí para obtener una pista**

Desarrollo y evaluación de modelos

Separa del dataset

```
In [36]: # Separa los datos de entrenamiento y evaluación
# Siguiendo instrucciones de Hugo Ramallo importo de la librería SKLEARN train test split,
# también estandarizo los datos para que funcione mejor el modelo

from sklearn.model_selection import train_test_split

# La variable objetivo Y es class, la separ del resto de variables mediante Drop y dejo en X el resto de variables

X = data_limpia.drop('Class', axis=1)
y = data_limpia['Class']

# Aqui separo los datos, uso el argumento random_state valor 42 ya que es el número comunmente utilizado, según he podidido averiguar

X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)

# Imprimo el tamaño de los datos para comprobación según se aconseja por Hugo
print("Tamaño del conjunto de entrenamiento (X_train):", X_train.shape)
print("Tamaño del conjunto de evaluación (X_test):", X_test.shape)
print("Tamaño del conjunto de entrenamiento (y_train):", y_train.shape)
print("Tamaño del conjunto de evaluación (y_test):", y_test.shape)

# En la Tutoria sesión 5 Hugo comenta que estandaricemos los datos para tener mejores resultados y que el modelo funcione más eficazmente

from sklearn.preprocessing import StandardScaler

# Uso scaler para ello y  estandarizo los datos de entrenamiento y test (excepto los valores objetivo y, ya que ya son 0 y 1)
scaler = StandardScaler()
X_train = scaler.fit_transform(X_train)
X_test = scaler.transform(X_test)

Tamaño del conjunto de entrenamiento (X_train): (226980, 30)
Tamaño del conjunto de evaluación (X_test): (56746, 30)
Tamaño del conjunto de entrenamiento (y_train): (226980,)
Tamaño del conjunto de evaluación (y_test): (56746,)
```

▶ **Haz clic aquí para obtener una pista**

Crea y evalúa los modelos

```
In [39]: # Escribe tu código aquí

# Siguiendo la pista y tutoria de Hugo usaré en primer lugar el método RandomForest para entrenar el módelo y predict para las predicciones
# Bibliotecas necesarias
from sklearn.ensemble import RandomForestClassifier
from sklearn.metrics import classification_report, accuracy_score

# Defino modelo RandomForestClassifier con los hiperparámetros indicados y lo entreno con los datos train mediante  .fit()

modelo = RandomForestClassifier(max_depth=150, random_state=42)

modelo.fit(X_train, y_train)

# Almaceno las predicciones sobre los datos de evaluación en y_pred
y_pred = modelo.predict(X_test)

# Reporte de clasificación
print("Resumen de rendimiento:")
print(classification_report(y_test, y_pred))

# Exactitud del modelo
exactitud = accuracy_score(y_test, y_pred)
print(f"La exactitud del modelo es: {exactitud * 100:.2f}%")

Resumen de rendimiento:
              precision    recall  f1-score   support

           0       1.00      1.00      1.00     56656
           1       0.97      0.73      0.84        90

    accuracy                           1.00     56746
   macro avg       0.99      0.87      0.92     56746
weighted avg       1.00      1.00      1.00     56746

La exactitud del modelo es: 99.95%
```

```
In [40]: # Pruebo el uso del modelo SVM para poder comparar que modelo funciona mejor, repetimos entreno y evaluación
# Importo bibliotecas necesarias
from sklearn.svm import SVC

# Inicializar el clasificador SVM
model_SVM = SVC(kernel='rbf', C=1, gamma='scale', probability=True)

# Entrenar el modelo
model_SVM.fit(X_train, y_train)

# Almaceno las predicciones sobre los datos de evaluación en SVM_pred
SVM_pred = model_SVM.predict(X_test)

# Reporte de clasificación
print("Resumen de rendimiento modelo SVM Máquina de Vectores de Soporte:")
print(classification_report(y_test, SVM_pred))

# Exactitud del modelo
exactitud_SVM = accuracy_score(y_test, SVM_pred)
print(f"La exactitud del modelo es: {exactitud_SVM * 100:.2f}%")

Resumen de rendimiento modelo SVM Máquina de Vectores de Soporte:
              precision    recall  f1-score   support

           0       1.00      1.00      1.00     56656
           1       0.98      0.64      0.78        90

    accuracy                           1.00     56746
   macro avg       0.99      0.82      0.89     56746
weighted avg       1.00      1.00      1.00     56746

La exactitud del modelo es: 99.94%
```

▶ **Haz clic aquí para obtener una pista**

```
In [42]: from sklearn.metrics import confusion_matrix

print(confusion_matrix(y_test, y_pred))

print(confusion_matrix(y_test, SVM_pred))

[[56654     2]
 [   24    66]]
[[56655     1]
 [   32    58]]
```

Comentarios finales extraidos de el analisis realizado por Chat-GPT:

Análisis de los Resultados

Has aplicado y evaluado dos modelos de Machine Learning: **RandomForest** y **SVM** (Máquina de Vectores de Soporte) sobre un dataset de detección de fraudes con tarjetas de crédito, utilizando datos estandarizados. Vamos a analizar los resultados obtenidos por ambos modelos y extraer conclusiones.

1. **Resultados del Modelo RandomForest**

- **Resumen de rendimiento:**
    - **Precision (clase 1):** 0.97
    - **Recall (clase 1):** 0.73
    - **F1-score (clase 1):** 0.84
    - **Exactitud del modelo:** 99.95%
- **Matriz de confusión:**
    - [[56654, 2], [24, 66]]

Interpretación:

- **Precisión:** El modelo identifica correctamente el 97% de las transacciones que predice como fraudulentas.
- **Recall:** El modelo detecta el 73% de las transacciones realmente fraudulentas. Es decir, de las 90 transacciones fraudulentas, el modelo detecta 66 correctamente, y falla en 24.
- **F1-Score:** El F1-Score de 0.84 para la clase 1 (fraudulenta) indica un buen balance entre precisión y recall, lo que es importante en contextos donde el coste de falsos negativos (transacciones fraudulentas no detectadas) es alto.
- **Matriz de confusión:** El modelo solo falla en 26 casos (2 falsos positivos y 24 falsos negativos), lo que indica un excelente rendimiento general.

2. **Resultados del Modelo SVM**

- **Resumen de rendimiento:**
    - **Precision (clase 1):** 0.98
    - **Recall (clase 1):** 0.64
    - **F1-score (clase 1):** 0.78
    - **Exactitud del modelo:** 99.94%
- **Matriz de confusión:**
    - [[56655, 1], [32, 58]]

Interpretación:

- **Precisión:** El modelo SVM es ligeramente más preciso que RandomForest, con un 98% de precisión en la detección de transacciones fraudulentas.
- **Recall:** Sin embargo, su capacidad para detectar transacciones fraudulentas es menor, con un 64% (el modelo no detecta 32 de las 90 transacciones fraudulentas).
- **F1-Score:** El F1-Score de 0.78 es menor que el de RandomForest, lo que sugiere un menor equilibrio entre precisión y recall.
- **Matriz de confusión:** El modelo comete más errores que RandomForest, con 33 errores (1 falso positivo y 32 falsos negativos).

3. **Comparación entre RandomForest y SVM**

- **Precisión:** Ambos modelos son altamente precisos, pero SVM tiene una precisión ligeramente superior en la detección de transacciones fraudulentas.
- **Recall:** RandomForest tiene un mejor recall, lo que significa que detecta una mayor proporción de transacciones fraudulentas. Esto es crucial en el contexto de detección de fraudes, donde los falsos negativos (fraudes no detectados) tienen un alto coste.
- **F1-Score:** RandomForest tiene un F1-Score superior, lo que indica un mejor equilibrio general entre precisión y recall.
- **Matriz de confusión:** RandomForest comete menos errores globales en comparación con SVM, lo que lo hace más confiable en la detección de fraudes.

Conclusiones Finales

1. **Modelo Recomendado: RandomForest**:
    - **Mejor equilibrio**: El modelo RandomForest presenta un mejor equilibrio entre precisión y recall, lo que lo hace más adecuado para la detección de fraudes, donde es crítico identificar la mayor cantidad posible de transacciones fraudulentas.
    - **Menos errores**: RandomForest comete menos errores en términos de falsos negativos, lo cual es preferible en la mayoría de los contextos de seguridad.
2. **Uso de SVM como apoyo**:
    - **Precisión superior**: Aunque SVM tiene una precisión ligeramente superior, su menor recall y mayor número de errores falsos negativos lo hacen menos confiable como modelo principal.
    - **Posible complemento**: SVM podría ser útil como un modelo complementario si se utilizan técnicas de ensamblado o si se busca un segundo punto de referencia en el sistema de detección.
3. **Estandarización de datos**:
    - **Necesidad para SVM**: Como observaste, la estandarización es crítica para el rendimiento del modelo SVM. Sin estandarización, este modelo falla drásticamente.
    - **RandomForest es robusto**: Este modelo muestra un rendimiento consistente independientemente de la estandarización, lo que lo hace versátil y fácil de aplicar.

Recomendación Final

Para la implementación práctica, te recomendaría usar **RandomForest como el modelo principal** debido a su mayor fiabilidad y menor tasa de errores. Si decides utilizar SVM, asegúrate de que los datos estén correctamente estandarizados y considera su uso como un modelo complementario para mejorar la precisión del sistema general de detección de fraudes.

```
In [ ]:
```